

# 简介

- **snowflake** 和 **databrick** 两款产品资料收集。
- 产品选型上，两款产品面向的用户群体是不一样的，存在较为明显的区别，相似用户群在数据分析师。
- 在技术选型上，两款产品的技术路线存在不同，导致彼此之间存在优缺点之间的互补。
- 从用户反馈上看，**snowflake**的评分要高于**databrick**。

# 目录

- 架构
- 产品形态
- 用户场景
- 用户反馈

# 1. 架构-Snowflake vs DataBricks


## snowflake:

- 面向数据仓库  
结构化、半结构数据等
- 主要面向数据开发人员
- mpp
- 抽象化帮助理解:  
将架构抽象成存储、计算和服务。  
用户只需关心服务层面, 而不用下沉到具体的计算资源、存储资源等层面
- 安全:  
端到端的计算链、数据存储
- 公有云为主
- 以sql为主
- 按需计费、事后计费


## databrick:

- 面向数据湖  
结构化、半结构化、无结构数据等
- 主要面向数据分析和AI工程师,  
主打data+AI
- spark
- 用户不仅需要关心服务层面, 也需要关心一些底层云设施
- 支持混合云
- sql/python等多语言

## Databricks Lakehouse



## Snowflake Cloud Data Platform



# 1. 架构-参考

- **snowflake与databrick对比**:<https://www.datagrom.com/data-science-machine-learning-ai-blog/snowflake-vs-databricks>
- **snowflake论文**:<http://pages.cs.wisc.edu/~yxy/cs839-s20/papers/snowflake.pdf>
- **论文解读和引申**:<https://zhuanlan.zhihu.com/p/56745552>

## 2.产品的形态

- Snowflake 简洁、易上手，侧重于数仓，适用于数据工程师和分析师等。
  - introduction: <https://resources.snowflake.com/youtube-all-videos/snowflake-introduction-demo>
  - demo: <https://resources.snowflake.com/youtube-all-videos/concurrency-in-snowflake>
- DataBrick 简洁，功能较多，侧重于分析，适用于数据科学家、数据分析师等。
  - sql: <https://databricks.com/discover/demos/databricks-sql>
  - demos: <https://databricks.com/discover/demos>

# 3. 用户场景 - snowflake

- 小中大型数据收集公司:
  - 数据共享; 跨地域数据获取;
- 商业智能团队:
  - 营销与产品决策等数据的获取与简要分析
- 中小型数仓团队

# 3. 用户反馈-snowflake

## 技术优点

- 云：扩展性、计算性能、免维护，易于云端集成，存储和计算分离。
- 数据的存储、组织、管理方便；与aws s3 无缝集成；
- 近实时的查询，优化的查询引擎、支持标准的ANSI sql语言
- 即使账号内的员工数增加、也不影响系统的稳定性。
- 数据迁移方便、易与其他数据中心连接；
- 无索引的设计，可以让用户不用花时间在管理和维护解决方案上，而是关注业务。

## 产品优点：

- 安全的数据共享：与供应商间的数据传输，与公司内部经理间数据共享（工作协同）；与业务方共享业务看板/商业洞察；简单易用且透明；
- 易于与其他bi分析工具的联动等（tableau\power bi\sql server）；还可以将用户的sql ide连接到snowflake
- 友好的用户查询界面，上手简单、易于初学者。查询建议、表可以拖拽到查询中。
- 免费试用
- 成本控制：按需计费；计算和存储计费分开；

# 3.用户反馈-snowflake

## • 缺点

- 不能恢复误删的查询表
- 文档不完善
- 不能支持PLSQL
- 图表功能有待改进、报表功能需要跟第三方联动;
- 可备选的产品: Informatica Enterprise Data Integration 、 TreasureData
- 不适用于没上云的企业 (感觉是公有云的锅)
- 没有存储查询代码的功能, 需要重新查询
- 多用户同时使用, 存在性能瓶颈 (感觉是mpp的锅)
- 技术支持响应不及时
- 不支持Dynamic SQL
- 不支持python等语言
- 复杂查询速度缓慢
- 用户业务的SLA会受三大云商的影响
- 任务调度功能不足

## 4. 用户场景-databrick

- 大型的数据转换与分析：同时处理海量数据、可视化
- 数据科学家团队

# 4. 用户反馈-databrick

- 优点:

- 与Azure无缝集成
- 数据加载、提取、转换、集成的处理速度快,
- 多语言支持 (python等)
- 界面简单
- github的集成
- DAG任务调度管理
- ML flow
- 灵活的编写代码和自动化运行任务
- 帮助托管spark集群
- notebook对协同工作有帮助, 类似terminal便于编码环境。
- 数据处理到模型训练无缝集成

# 4. 用户反馈 - databrick

- 缺点:

- 没有免费试用环节
- 背后强依赖scala语言
- 价格相对高
- 单元测试支持不好
- 无法直接更新云数据库中的数据
- 集群创建时间漫长
- 存在非按需付费的问题。
- 不容易理解 (学习成本太高)
- 数据分析或挖掘时, 参数还是手动, 希望可以自动
- 错误提示不明显, 往往需要进一步去查找

# 4. 场景与用户反馈资料参考

- **sourceforge**: <https://sourceforge.net/software/compare/Cloudera-vs-Databricks-vs-Snowflake/>
- **g2**: <https://www.g2.com/compare/azure-databricks-vs-snowflake>
- **trustradius**: <https://www.trustradius.com/compare-products/databricks-lakehouse-platform-vs-snowflake>
- **etl角度考虑**: <https://www.confessionsofadataguy.com/databricks-vs-snowflake-the-datalake-warehouse-battle/>
- **kylingence关于snowflake的分析**: <https://kylingence.io/blog/snowflake-the-good-the-bad-and-the-beautiful-for-analytics/>